



Matrix factorization for recommender systems

Kaoutar Boulif, Eric N'guessan, Salma Elghourbal
M2 IASD

PLAN



1- Exploration des données

2- Stratégie de split en train/test

3- La méthode SVD

4- Algorithme ALS




5- Algorithme Gradient descent

6- Algorithme PMF

7- Comparaison entre différentes approches

1. Exploration des données

- base de données MovieLens décrit préférences utilisateurs pour des films
- la base de données MovieLens (version Small) contient 100,000 ratings, environ 9000 films et 600 utilisateurs.
- Matrice de Ratings R_{small} (610,9724) est creuse à 98.3%
- Chaque utilisateur a au moins évalué 20 films
- La majorité des films ont moins de 25 notes.



2- Préparation des données et évaluation des méthodes de MF

Stratégie split train/test

Train set = la matrice R pour laquelle on enlève aléatoirement 15 ratings par user

Test set = une matrice de même dimension contenant uniquement les 15 ratings par user qu'on a enlevés

$$RMSE(R, \hat{R}, T) = \sqrt{\frac{\sum_{(i,u) \in T} (R_{iu} - \hat{R}_{iu})^2}{|T|}}$$

Where:

- R in the original rating matrix (sparse)
- \hat{R} is the estimated rating matrix (dense)
- $T = \{(u, i) \mid R_{iu} \text{ is in the testing set}\}$

Objectif : Bonne prédiction des ratings du test set avec une méthode de factorisation de matrice en approchant R avec un produit de matrices de type : $R \sim U^* \text{ transpose}(V)$



2. Méthode de la SVD (Singular value decomposition)

Formulation : trouver U, V, S tels que : $R \approx USV^T$

S : matrice diagonale de dimension $k \times k$, U matrice des utilisateurs, V matrice des films

Implémentation : package svds de Scipy

Expériences : Impact du choix de k sur la RMSE



Valeur optimale : **k= 25**

RMSE de test minimale :

3.2448

RMSE de train correspondant :

2.2788

3- La méthode ALS

Formulation: $C(I, U) = \|R - IU^\top\|_{\mathcal{F}}^2 + \lambda \|I\|_{\mathcal{F}}^2 + \mu \|U\|_{\mathcal{F}}^2$



$$\frac{\partial C}{\partial I}(I, U) = -2RU + 2IU^\top U + 2\lambda I = 0$$

$$\frac{\partial C}{\partial U}(I, U) = -2R^\top I + 2UI^\top I + 2\mu U = 0$$

$$I_{t+1} = RU_t(U_t^\top U_t + \lambda \mathbb{I})^{-1}$$

$$U_{t+1} = R^\top I_t(I_t^\top I_t + \mu \mathbb{I})^{-1}$$

Expérience 1:




4- Descente de Gradient

Formulation: $C(I, U) = \|R - IU^\top\|_{\mathcal{F}}^2 + \lambda \|I\|_{\mathcal{F}}^2 + \mu \|U\|_{\mathcal{F}}^2$

- $I_{t+1} = I_t - \eta_t \frac{\partial C}{\partial I}(I_t, U_t)$
- $U_{t+1} = U_t - \xi_t \frac{\partial C}{\partial U}(I_t, U_t)$

Résultats:



Pros/Cons: -temps
d'exécution très lent,
+erreur RMSE faible

5- Probabilistic matrix factorization


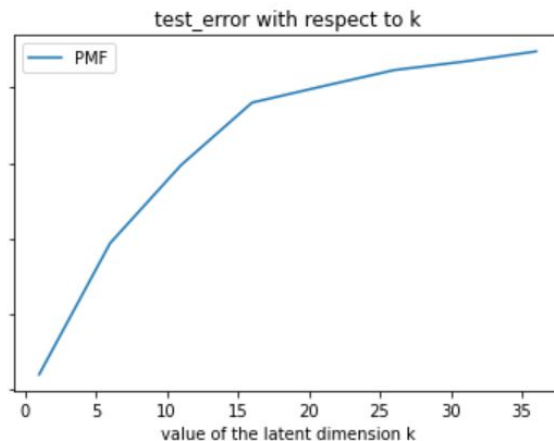
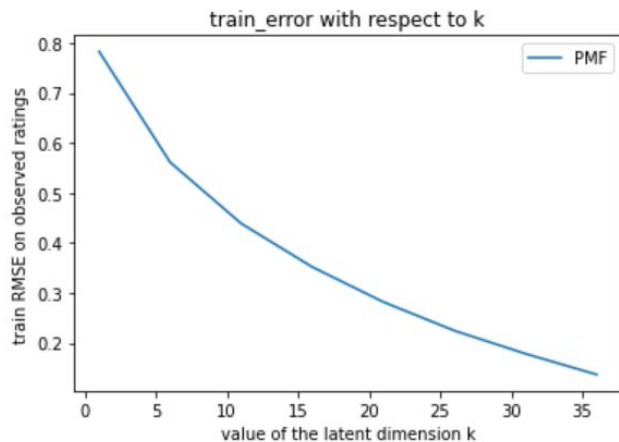
Formulation : Trouver U et V qui maximisent la distribution A posteriori

Ce qui est équivalent à maximiser L

$$L = -\frac{1}{2} \left(\sum_{i=1}^N \sum_{j=1}^M (R_{ij} - U_i^T V_j)^2_{(i,j) \in \Omega_{R_{ij}}} + \lambda_U \sum_{i=1}^N \|U_i\|_{Fro}^2 + \lambda_V \sum_{j=1}^M \|V_j\|_{Fro}^2 \right)$$


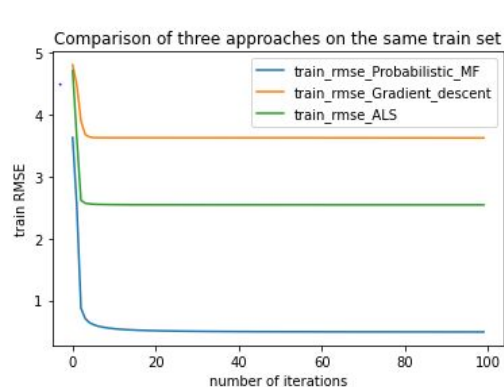
Implémentation une ALS sur les lignes U_i et V_j

Expériences : Impact du choix de k sur la RMSE

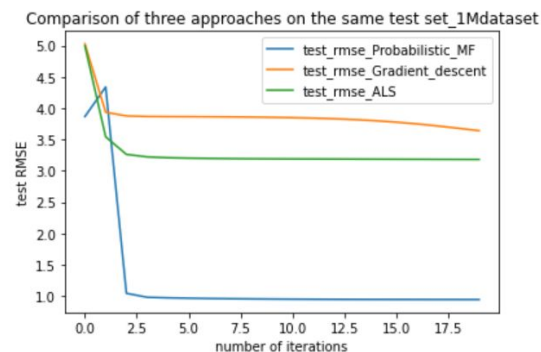
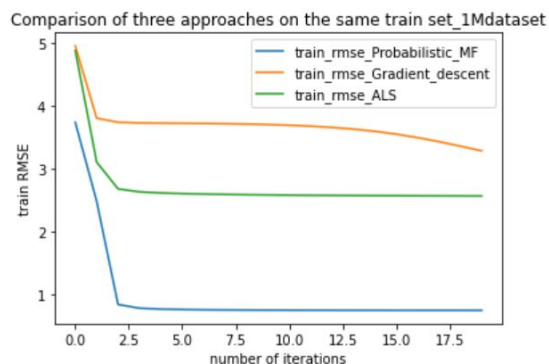


6- Comparaison des méthodes

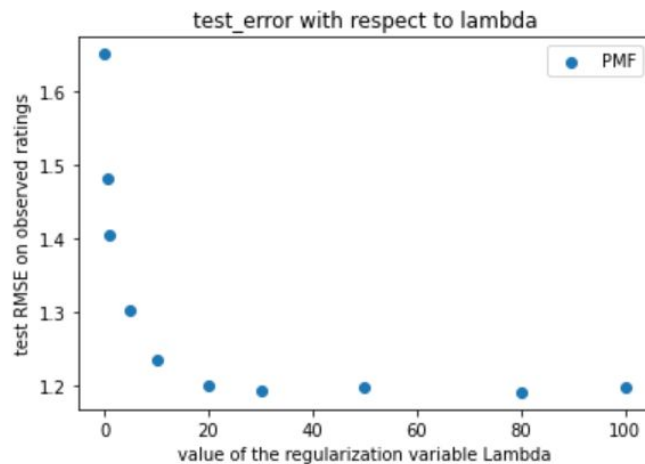
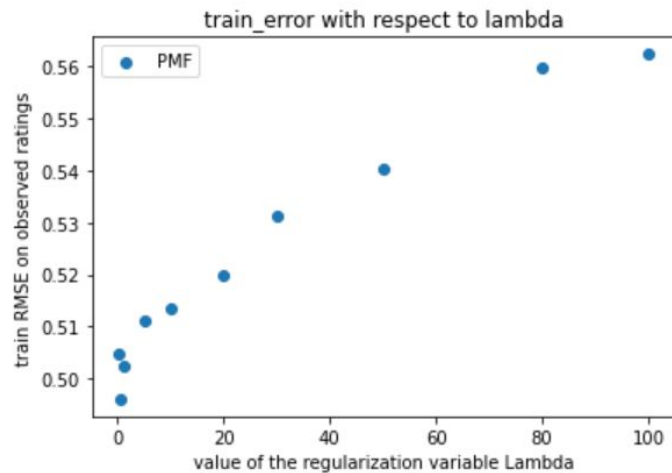
a- Dataset 1 (610 users, 9742 movies)



b- Dataset 2 (6040 users, 3706 movies)



ANNEXES - PMF



ANNEXES - ALS

